

HPC Aplicado con R

George G. Vega Yon

2024-09-04

Table of contents

Prefacio	5
Sobre el Autor	5
Sobre la versión en Español	5
Divulgación sobre IA	6
Sobre la portada	6
I Fundamentos	7
1 Perfilado de Código	8
1.1 Un flujo de trabajo propuesto	9
1.2 Perfilado de código en R	9
1.3 Ejercicio: Identificando el cuello de botella	11
2 Escribiendo Código Eficiente	13
2.1 Operaciones Vectorizadas	13
2.2 Cacheando cálculos	14
2.3 Cacheando cálculos (bis)	15
2.4 Cacheando cálculos en una ShinyApp	17
2.5 Evitando pasos innecesarios	19
2.6 Reduciendo operaciones de copia	19
II Computación paralela	21
3 Introducción a la Computación Paralela	22
4 Introducción	23
5 Computación de Alto Rendimiento: Una visión general	24
5.1 Big Data	24
5.2 Computación paralela	25
5.2.1 Serial vs. Paralelo	26
5.3 Computación de alto rendimiento en R	27
5.3.1 Algo de vocabulario para HPC	27
5.4 GPU vs. CPU	28
5.5 ¿Cuándo es una buena idea?	29

5.6	Computación paralela en R	29
6	El Paquete parallel	31
6.1	El Paquete <code>parallel</code> en R	31
6.2	Funciones Principales	31
III	Trabajando con un Cluster	33
7	Fundamentos de SLURM	34
8	¿Qué es Slurm?	35
8.1	Definiciones	35
9	Una introducción breve a Slurm	37
9.1	Paso 1: Copiar el script de Slurm a HPC	37
9.2	Paso 2: Iniciar sesión en HPC	38
9.3	Paso 3: Enviando el trabajo	38
10	SLURM con Simulación de	39
11	Simulando <i>pi</i>	40
11.1	Enviando trabajos a Slurm	41
11.1.1	Caso 1: Trabajo único, trabajo de un solo núcleo	42
11.1.2	Caso 2: Trabajo único, trabajo multinúcleo	43
11.2	Trabajos con el paquete <code>slurmR</code>	44
11.2.1	Caso 3: Trabajo único, trabajo multinodo	44
11.2.2	Caso 4: Múltiples trabajos, un solo/múltiples núcleos	45
11.2.3	Caso 5: Omitiendo el archivo <code>.slurm</code>	47
IV	Usando C++	49
12	Rcpp Parte 1	50
12.1	Introducción a Rcpp	50
12.2	¿Por qué usar C++ con R?	50
12.3	Primer Ejemplo	50
13	Depuración de R con código C++/C	52
14	Depuración de R con código C++/C	53
14.1	Depuración con Valgrind	53
14.2	Usando GDB	57
15	Misceláneos	65
15.1	Recursos generales	65

15.2	Punteros de datos	65
15.3	Las opciones de Slurm que se olvidaron de contarte...	66
15.4	Buenas prácticas (recomendaciones)	67
15.5	Ejecutando R interactivamente	67
15.6	NoNos cuando uses R	68
16	Referencias	69
Referencias		70
16.1	Recursos Adicionales	70
16.1.1	Libros Recomendados	70
16.1.2	Sitios Web y Documentación	70
16.1.3	Paquetes Relevantes	71

Prefacio

El lenguaje de programación R (R Core Team 2023) puede ser fantástico para la mayoría de las tareas diarias. Pero tan pronto como comienzas a lidiar con problemas más complicados, puedes enfrentarte al cuello de botella del bucle for. Si alguna vez te encuentras con tal problema, este libro es para ti. HPC Aplicado con R es una colección de charlas y conferencias que he dado sobre cómo acelerar tu código R usando computación paralela y otros recursos como C++. Los contenidos se han desarrollado principalmente durante mi tiempo en USC y UofU.¹

El libro fue escrito usando [quarto](#) y está alojado en [GitHub](#), donde puedes acceder a todo el código fuente.

Sobre el Autor

Soy Profesor Asistente de Investigación en la **División de Epidemiología de la Universidad de Utah**, donde trabajo estudiando Sistemas Complejos utilizando Computación Estadística. Nací y crecí en Chile. Tengo más de diez años de experiencia desarrollando software científico con enfoque en computación de alto rendimiento, visualización de datos y análisis de redes sociales. Mi formación es en Políticas Públicas (M.A. UAI, 2011), Economía (M.Sc. Caltech, 2015), y Bioestadística (Ph.D. USC, 2020).

Obtuve mi Ph.D. en Bioestadística bajo la supervisión del **Prof. Paul Marjoram** y la **Prof. Kayla de la Haye**, con mi disertación titulada “*Essays on Bioinformatics and Social Network Analysis: Statistical and Computational Methods for Complex Systems.*”

Si deseas aprender más sobre mí, por favor visita mi sitio web en <https://ggvy.cl>.

Sobre la versión en Español

Esta versión en español del libro fue creada para hacer accesible el contenido sobre computación de alto rendimiento con R a la comunidad hispanohablante. Aunque se ha hecho un esfuerzo por mantener la precisión técnica y el contexto, algunos términos especializados

¹Con muchos a quienes agradecer, incluyendo [Paul Marjoram](#), [Zhi Yang](#), [Emil Hvitfeldt](#), [Malcolm Barrett](#), [Garrett Weaver](#), el grupo de investigación IMAGE P01 de USC, y mis estudiantes tanto en USC como en UoU.

pueden requerir revisión adicional. La versión original en inglés permanece como la referencia autorizada.

Los lectores que encuentren errores de traducción o áreas que requieran clarificación son bienvenidos a contribuir reportando problemas en el repositorio de GitHub del proyecto.

Divulgación sobre IA

A partir de mediados de 2023, he estado utilizando IA para ayudarme a escribir este libro. Principalmente, uso una combinación de [GitHub co-pilot](#), que ayuda con código y texto. El papel de la IA ha sido ayudarme a escribir más rápido y con mayor precisión, pero no ha estado involucrada en la conceptualización del libro o el desarrollo de los métodos presentados aquí.

Sobre la portada

La imagen de portada fue creada usando ChatGPT/Dall-E versión 5 usando el prompt “Necesito que dibujes una imagen que represente computación de alto rendimiento usando el lenguaje de programación R (que se usa principalmente para estadística). La imagen irá como portada del libro”Applied HPC with R”. Debería incluir componentes relacionados con C++, computación paralela, y computación de alto rendimiento”

Part I

Fundamentos

1 Perfilado de Código

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

El perfilado de código es una herramienta fundamental para programadores. Con el perfilado, es posible **identificar posibles cuellos de botella en tu código**, así como uso excesivo de memoria. Algunas cosas importantes a considerar al perfilar tu código:

- **Tiene un componente estocástico:** Independientemente de la complejidad computacional, un programa puede exhibir diferentes características de rendimiento en diferentes ejecuciones. Esto significa que siempre debes perfilar tu código múltiples veces y tomar el rendimiento promedio como resultado final.
- **Es inútil si el programa es demasiado rápido:** La mayoría del tiempo, el perfilado de código debe hacerse en programas que toman una cantidad notable de tiempo para ejecutarse. Si un programa se ejecuta demasiado rápido, la sobrecarga del perfilado mismo puede sesgar los resultados. Si aún necesitas abordar esto, puedes, por ejemplo, hacer múltiples ejecuciones o usar un conjunto de datos más grande para aumentar el tiempo de ejecución del programa.
- **No lo hagas demasiado temprano:** La mayoría del tiempo, los desarrolladores tienden a optimizar (y por tanto perfilar) su código demasiado temprano. No quieres gastar tiempo haciendo perfilado de código en algo que podría cambiar rápidamente. Por lo tanto, es mejor hacerlo en código que funciona en lugar de en piezas del mismo.

En lugar de perfilar el código demasiado temprano, asegúrate de tener un buen plan de diseño e implementación.


- **Sé estratégico:** No todo necesita ser optimizado. Enfócate en las partes del código que son críticas para el rendimiento y la experiencia del usuario. Puedes pensar en términos de cuánto tiempo el programa/usuario gasta en cada parte.
- **La IA puede darte buenos consejos:** En mi experiencia personal, la IA puede ser útil para hacer perfilado de código también. Esto funciona mejor si estás usando una [IA agéntica](#), ya que es más probable obtener buena retroalimentación de ella (probará el código por ti).

Aquí hay un flujo de trabajo propuesto para perfilar y optimizar tu código en general

1.1 Un flujo de trabajo propuesto

Aquí hay una fórmula a seguir cuando hagas perfilado/optimización de código:

1. Hazte estas preguntas antes de saltar al perfilado:



2. Si tienes éxito, entonces asegúrate de que el perfilado se haga en un tiempo finito, esto es, usa un subconjunto de los datos para evitar esperas largas. **Ejecutar el perfilador agregará tiempo de cómputo adicional, así que trata de mantenerlo corto (p. ej., 1 minuto).**
3. Puede haber muchas cosas que podrían ser optimizadas, enfócate en lo que entregaría el mayor impacto. Podría ser una función que solo se llama una vez pero toma mucho tiempo para ejecutarse, o una función que se llama múltiples veces pero es relativamente rápida.
4. Antes de hacer cualquier cambio, asegúrate de tener una copia de seguridad de tu código original, así como una copia de los resultados actuales del perfilado. **También debes asegurar guardar (si es posible) el resultado del código.**
5. Vuelve a ejecutar el perfilador y compara el rendimiento. Si no se observan cambios, entonces regresa al paso 2. **Asegúrate de que la nueva versión del código mantenga la misma funcionalidad que el original (verifica los resultados).**

1.2 Perfilado de código en R

En el lenguaje de programación R, la herramienta de perfilado más utilizada viene con el [paquete profvis](#). El paquete proporciona un envoltorio de la función `Rprof`, que es una función incorporada de R para perfilar código. El paquete `profvis` hace más fácil visualizar los resultados del perfilado en una interfaz web.

Para usar `profvis`, primero necesitas instalarlo desde CRAN:

```
install.packages("profvis")
```

Luego, puedes usarlo para perfilar tu código R de esta manera:

```
library(profvis)


profvis({
  # Tu código R aquí
})
```

Esto ejecutará el código y generará una visualización de los resultados del perfilado en una nueva ventana del navegador. También puedes guardar la salida usando el paquete `htmlwidgets`:

```
pv <- profvis({
  # Tu código R aquí
})

htmlwidgets::saveWidget(pv, "profvis.html")
```

Una vez abierto, verás dos visualizaciones: el gráfico de llama y los datos. El gráfico de llama es una de las visualizaciones más útiles. Mapea directamente el tiempo y la memoria utilizados por cada línea de código



La visualización de datos muestra la distribución del tiempo gastado en cada función. Usando una estructura de árbol, que permite profundizar en la pila de llamadas.

Flame Graph	Data	Options ▾		
Code	File	Memory (MB)		Time (ms)
▼ apply	<expr>	-603.2	1092.6	440
aperm.default		0	457.8	140
mean.default		-211.0	297.6	140
as.matrix.data.frame		0	0	80
<GC>		-193.8	53.4	40
data1[, names(data1) != "id"][, i] <- data1[, names(data1) != "id"][, i] - means[i]	<expr>	0	355.8	60
[<-.data.frame	<expr>	0	59.1	20

Sample Interval: 10ms

520ms

💡 Tip

Cuando desarrolles paquetes de R, es una buena idea emparejar tu llamada `profvis::profvis` con `devtools::load_all()` para asegurar que todo el código fuente esté disponible para el perfilador. De lo contrario, el gráfico de llama no mostrará tu código (dirá “no disponible”).

1.3 Ejercicio: Identificando el cuello de botella¹

```
# Generate data
times <- 4e5
cols <- 150
data <- as.data.frame(x = matrix(rnorm(times * cols, mean = 5), ncol = cols))
data <- cbind(id = paste0("g", seq_len(times)), data)

pv <- profvis::profvis({
  data1 <- data # Store in another variable for this run

  # Get column means
  means <- apply(data1[, names(data1) != "id"], 2, mean)

  # Subtract mean from each column
  for (i in seq_along(means)) {
    data1[, names(data1) != "id"][, i] <- data1[, names(data1) != "id"][, i] - means[i]
```

¹Código copiado literalmente del paquete R `profvis` [aquí](#).

```
    }  
  })  
  
htmlwidgets::saveWidget(pv, "profvis-slow-code.html")  
  
# In interactive mode, we can directly view the profiling results  
if (interactive())  
  print(pv)
```

¿Puedes identificar dónde está el cuello de botella en el código? ¿Qué harías para acelerarlo?

2 Escribiendo Código Eficiente

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

- El código R puede ser muy eficiente para tareas típicas, pero, a medida que el código comienza a aumentar en complejidad, es fácil que se vuelva ineficiente.
- Algunos consejos rápidos de R para código de computación eficiente:
 - Usa operaciones vectorizadas en lugar de bucles.
 - Trata de usar caché para evitar cálculos repetidos. ¡El caché también se puede hacer fuera de la memoria!
 - Evita pasos/procesamiento de datos innecesarios.
 - Reduce el número de operaciones de copia.

2.1 Operaciones Vectorizadas

La vectorización puede significar muchas cosas en programación, pero en R, la vectorización se refiere a usar funciones sobre vectores. Por ejemplo, en lugar de usar un bucle para sumar dos vectores juntos, puedes usar el operador `+` directamente en los vectores:

```
# Using a loop
set.seed(331)
a <- runif(1e3)
b <- runif(1e3)
result <- numeric(length(a))
for (i in seq_along(a)) {
  result[i] <- a[i] + b[i]
}

# Using vectorized operation
result <- a + b
```

Incluso podemos hacer benchmark del rendimiento de estos dos enfoques:

```
library(microbenchmark)
microbenchmark(
  loop = {
    result <- numeric(length(a))
    for (i in seq_along(a)) {
      result[i] <- a[i] + b[i]
    }
  },
  vectorized = {
    result <- a + b
  },
  unit = "relative"
)
```

Unit: relative

expr	min	lq	mean	median	uq	max	neval
loop	2322.232	1267.757	602.0661	557.761	497.6105	437.0931	100
vectorized	1.000	1.000	1.0000	1.000	1.0000	1.0000	100



Tip

Los bucles for no siempre son malos. El problema principal está con el código dentro del bucle for. Si el código ya está vectorizado, entonces no hay necesidad de eliminar el bucle for (a menos que puedas vectorizar el bucle for mismo).

2.2 Cacheando cálculos

Muchas veces, es útil cachear cálculos que son costosos de computar. Por ejemplo, si tienes una función que toma mucho tiempo para ejecutarse, puedes almacenar el resultado en una variable y reutilizarlo más tarde en lugar de recalcularlo.

Aquí hay un mal ejemplo usando la secuencia de Fibonacci:

```
fibonacci <- function(n) {
  if (n <= 1) {
    return(n)
  }
  return(fibonacci(n - 1) + fibonacci(n - 2))
}

fibonacci_cached <- function(n) {
  prev <- numeric(n + 1)
```

```

for (i in seq_len(n)) {
  if (i <= 1) {
    prev[i + 1] <- i
  } else {
    prev[i + 1] <- prev[i] + prev[i - 1]
  }
}

return(prev[n + 1])
}

```

Ambas funciones deberían devolver el mismo resultado, pero la segunda es significativamente más rápida ya que evita llamar la función recursivamente:

```

microbenchmark(
  fibonacci(10),
  fibonacci_cached(10),
  times = 10,
  unit = "relative",
  check = "equal"
)

```

Unit: relative

	expr	min	lq	mean	median	uq	max
	fibonacci(10)	24.01182	22.86196	14.18542	20.67796	18.95371	4.512009
	fibonacci_cached(10)	1.00000	1.00000	1.00000	1.00000	1.00000	1.000000
neval							
	10						
	10						

2.3 Cacheando cálculos (bis)

En el caso de cálculos grandes, también podemos guardar resultados en el disco. Por ejemplo, si estamos ejecutando una simulación/cálculo, uno por ciudad/escenario, podemos guardar los resultados en un archivo y leerlos más tarde. Aquí está cómo hacerlo:

Para cada valor de `i`, haz lo siguiente:

1. Verifica si el archivo `result_i.rds` existe.
2. Si no existe, ejecuta el cálculo y guarda el resultado en `result_i.rds`.
3. Si existe, lee el resultado de `result_i.rds`.

¡Así de simple! Aquí hay un ejemplo usando código R:

```
# A complicated simulation function
simulate <- function(i, seed) {
  set.seed(seed)
  rnorm(1e5)
}

# Generating seeds for each iteration
set.seed(331)
nsims <- 100
seeds <- sample.int(.Machine$integer.max, nsims)

# Just for this example, we will use a tempfile
res_0 <- vector("list", length = nsims)
for (i in seq_len(nsims)) {

  # Creating the filename
  fn <- file.path(tempdir(), paste0(i, ".rds"))

  # Does the result already exist?
  if (file.exists(fn))
    res_0[[i]] <- readRDS(fn)
  else {
    # If not, run the simulation and save the result
    res_0[[i]] <- simulate(i, seed = i)
    saveRDS(res_0[[i]], fn)
  }
}
```

Tip

Cuando ejecutes simulaciones, es una buena práctica establecer semillas individuales para cada simulación (si estas son individualmente complejas). De esa manera, si el código falla, puedes volver a ejecutar solo las simulaciones fallidas sin tener que rehacer todas.

Además, es una buena idea envolver tu código en una llamada `tryCatch()` para manejar errores con gracia. De esta manera, si una simulación falla, puedes registrar el error y continuar con la siguiente simulación sin detener todo el proceso.

```
# Just for this example, we will use a tempfile
res_0 <- vector("list", length = nsims)
for (i in seq_len(nsims)) {
```



```

# Creating the filename
fn <- file.path(tempdir(), paste0(i, ".rds"))

# Does the result already exist?
res <- tryCatch({
  if (file.exists(fn))
    readRDS(fn)
  else {
    # If not, run the simulation and save the result
    ans_i <- simulate(i, seed = i)
    saveRDS(ans_i, fn)
    ans_i
  }
}, error = function(e) e)

if (inherits(res, "error")) {
  message("Simulation ", i, " failed: ", res$message)
  next # Skip to the next iteration
}

# We still store it, even if it failed
res_0[[i]] <- res
}

```

Tip

La función `saveRDS` en R usa el argumento `compress = TRUE` como predeterminado. Comprimir los datos para ahorrar espacio es generalmente una buena idea, pero no si necesitas leer datos rápidamente. Entonces, si el espacio no es una restricción, puedes establecer `compress = FALSE` cuando guardes el archivo RDS para acelerar el proceso de lectura.

2.4 Cacheando cálculos en una ShinyApp

Abajo hay un ejemplo de una figura de plotly que está pre-grabada para una aplicación shiny. La idea es que, si la figura no necesita ser reactiva, siempre puedes pre-computar los resultados y almacenarlos en un archivo, en este caso, como un archivo HTML:

```

library(shiny)
library(bslib)

```

```

library(plotly)

# Like we did with the simulations, we have a default filename
fn <- "plotly.html"

# Notice I'm adding the www because, outside of the
# server call, this writes directly to the top level.
# Once reading, it will read from www.
if (!file.exists(file.path("www", fn))) {

  message("Creating the file...")

  # if it doesn't exist, then it creates it and saves it
  p <- plot_ly(x = 1:10, y = 1:10) %>% add_lines()
  htmlwidgets::saveWidget(
    p,
    file = "www/plotly.html",
    selfcontained = TRUE
  )
} else {
  message("The file already exists!")
}

# Define UI for app that draws a histogram ----
ui <- page_sidebar(
  # App title ----
  title = "Hello Shiny!",
  # Sidebar panel for inputs ----
  sidebar = sidebar(
    # Input: Slider for the number of bins ----
    sliderInput(
      inputId = "bins",
      label = "Number of bins:",
      min = 1,
      max = 50,
      value = 30
    )
  ),
  htmlOutput(outputId = "plotlyOutput")
)

server <- function(input, output) {

```

```

output$plotlyOutput <- renderUI({
  tags$iframe(
    src = "plotly.html"
  )
})

}

shinyApp(ui = ui, server = server)

```

2.5 Evitando pasos innecesarios

Muchas veces, podemos encontrar atajos para reducir la cantidad de procesamiento de datos que necesitamos hacer. Un gran ejemplo está en la función de regresión lineal `lm()`. La función `lm()` irá más allá de encontrar los coeficientes en un modelo lineal, también calculará residuos, valores ajustados, y más. En su lugar, podemos usar la función `lm.fit()` que solo calcula los coeficientes:

```

set.seed(331)
x <- rnorm(2e3)
y <- 2 + 3 * x + rnorm(2e3)

# Comparing
microbenchmark(
  lm = coef(lm(y ~ x)),
  lm_fit = coef(lm.fit(cbind(1, x), y)),
  times = 10,
  unit = "relative"
)

```

Unit: relative

expr	min	lq	mean	median	uq	max	neval
lm	6.073014	6.174112	7.344568	5.923627	6.280413	16.37963	10
lm_fit	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	10

2.6 Reduciendo operaciones de copia

Como en cualquier lenguaje de programación, las operaciones de copia en R pueden ser costosas. Más allá de aumentar la cantidad de memoria utilizada, las operaciones de copia requieren tiempo para asignar memoria y luego copiar los datos. R moderno minimiza estas

usando copy-on-modify. Esto significa que R no copiará un objeto hasta que sea modificado. Por ejemplo, el siguiente código hace múltiples copias de X, pero es hasta la última línea que R realmente hace una copia de X:

```
set.seed(331)
X <- runif(1e4)
Y <- X
Z <- X

# Checking the address of the objects
library(lobstr)
obj_addr(X)
## [1] "0x558609d2fd70"
obj_addr(Y)
## [1] "0x558609d2fd70"
obj_addr(Z)
## [1] "0x558609d2fd70"
```

Modificar X disparará una operación de copia, y las direcciones de Y y Z permanecerán iguales, mientras que X tendrá una nueva dirección:

```
# Modifying X
X[1] <- 100 # This is when R makes a copy of X
obj_addr(X)
## [1] "0x558609ff01d0"
obj_addr(Y)
## [1] "0x558609d2fd70"
obj_addr(Z)
## [1] "0x558609d2fd70"
```

Part II

Computación paralela

3 Introducción a la Computación Paralela



Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

4 Introducción

Aunque la mayoría de la gente ve R como un lenguaje de programación lento, tiene características poderosas que aceleran dramáticamente tu código ¹. Aunque R no fue necesariamente construido para la velocidad, hay algunas herramientas y formas en las que podemos acelerar R. Este capítulo introduce lo que entenderemos como computación de alto rendimiento en R.

¹No obstante, esta afirmación se puede decir sobre casi cualquier lenguaje de programación; hay ejemplos notables como el paquete R `data.table` (Dowle and Srinivasan 2021) que ha sido demostrado que [supera a la mayoría de herramientas de manipulación de datos](#).

5 Computación de Alto Rendimiento: Una visión general

Desde la perspectiva de R, podemos pensar en HPC en términos de dos o tres cosas:¹ Big data, computación paralela, y código compilado.

5.1 Big Data

Cuando hablamos de big data, nos referimos a casos donde tu computadora lucha para manejar un conjunto de datos. Un ejemplo típico de esto último es cuando el número de observaciones (filas) en tu marco de datos es [demasiado para ajustar un modelo de regresión lineal](#). En lugar de comprar una computadora más grande, hay muchas buenas soluciones para resolver problemas relacionados con la memoria:

- **Almacenamiento fuera de memoria.** La idea es simple, en lugar de usar tu RAM para cargar los datos, usa otros métodos para cargar los datos. Dos alternativas notables son los paquetes R [bigmemory](#) e [implyr](#). El paquete [bigmemory](#) proporciona métodos para usar matrices “*respaldadas por archivo*”. Por otro lado, [implyr](#) implementa un envoltorio para acceder a Apache Impala, un [motor de consultas SQL para un clúster ejecutando Apache Hadoop](#).
- **Algoritmos eficientes para big data:** Para evitar quedarte sin memoria con tu análisis de regresión, los paquetes R [biglm](#) y [biglasso](#) entregan alternativas altamente eficientes a [glm](#) y [glmnet](#), respectivamente. Ahora, si tus datos caben en tu RAM, pero aún luchas con la manipulación de datos, el paquete [data.table](#) es la solución.
- **Almacénalo más eficientemente:** Finalmente, cuando se trata de álgebra lineal, el paquete R [Matrix](#) brilla con sus clases formales y métodos para manejar Matrices Dispersas, *es decir*, matrices grandes cuyas entradas son principalmente ceros; por ejemplo, los objetos [dgCMatrix](#). Además, [Matrix](#) viene incluido con R, lo que lo hace aún más atractivo.

¹Asegúrate de revisar [CRAN Task View on HPC](#).

5.2 Computación paralela




Figure 5.1: Taxonomía Clásica de Flynn ([Blaise Barney, Introduction to Parallel Computing, Lawrence Livermore National Laboratory](#))

Nos enfocaremos en el **Single Instruction stream Multiple Data stream** (Flujo de Instrucción Única Flujo de Datos Múltiple).

En términos generales, un programa de computación paralela es uno en el cual usamos dos o más *hilos computacionales* simultáneamente. Aunque hilo computacional usualmente significa núcleo, hay múltiples niveles en los que un programa de computadora puede ser paralelizado. Para entender esto, primero necesitamos ver qué compone una computadora moderna:






Figure 5.2: Fuente: Figura original de la documentación del consorcio LUMI (LUMI consortium 2023)

Extensiones SIMD de Flujo [[SSE](#)] y Extensiones de Vector Avanzado [[AVX](#)]

5.2.1 Serial vs. Paralelo





Fuente: Blaise Barney, [Introduction to Parallel Computing](#), Lawrence Livermore National Laboratory




Figure 5.3: fuente: Blaise Barney, [Introduction to Parallel Computing](#), Lawrence Livermore National Laboratory

5.3 Computación de alto rendimiento en R

5.3.1 Algo de vocabulario para HPC

En términos crudos

- Supercomputadora: Una **sola** máquina grande con miles de núcleos/GPGPUs.
- Computación de Alto Rendimiento (HPC): **Múltiples** máquinas dentro de una **sola** red.

- Computación de Alto Rendimiento (HPC): **Múltiples** máquinas a través de **múltiples** redes.

Puede que no tengas acceso a una supercomputadora, pero ciertamente, los clústeres HPC/HTC son más accesibles hoy en día, *p. ej.*, AWS proporciona un servicio para crear clústeres HPC a bajo costo (supuestamente, ya que nadie entiende cómo funciona la tarificación)

5.4 GPU vs. CPU




Figure 5.4: [NVIDIA Blog](#)

- ¿Por qué usar OpenMP si GPU está *adecuado para operaciones intensivas en cómputo*? Bueno, principalmente porque OpenMP es **MUY** fácil de implementar (más fácil que CUDA, que es la forma más fácil de usar GPU).²

²Laboratorios Nacionales Sandia comenzó el [proyecto Kokkos](#), que proporciona una biblioteca C++ que se ajusta a todo para programación paralela. Más información en el [sitio wiki de Kokkos](#).

5.5 ¿Cuándo es una buena idea?




Figure 5.5: ¡Hazte estas preguntas antes de saltar a HPC!

5.6 Computación paralela en R

Mientras hay varias alternativas (solo echa un vistazo a la [Vista de Tareas de Computación de Alto Rendimiento](#)), nos enfocaremos en los siguientes paquetes R para **paralelismo explícito**:

- **parallel**: Paquete R que proporciona ‘[s]oporte para computación paralela, incluyendo generación de números aleatorios’.
- **future**: ‘[U]na API Future ligera y unificada para procesamiento secuencial y paralelo de expresiones R via futures.’
- **Rcpp + OpenMP**: **Rcpp** es un paquete R para integrar R con C++ y OpenMP es una biblioteca para paralelismo de alto nivel para C/C++ y FORTRAN.

Otros pero no usados aquí

- **foreach** para iterar a través de listas en paralelo.
- **Rmpi** para crear clústeres MPI.

Y herramientas para paralelismo implícito (herramientas listas para usar que permiten al programador no preocuparse por la paralelización):

- [gpuR](#) para manipulación de Matrices usando GPU
- [tensorflow](#) una interfaz R a [TensorFlow](#).

Una tonelada de otros tipos de recursos, notablemente las herramientas para trabajar con programadores de lotes como [Slurm](#), y [HTCondor](#).

6 El Paquete parallel

[El contenido completo de este capítulo será traducido al español. Por ahora, esta es una versión preliminar.]

6.1 El Paquete parallel en R

El paquete `parallel` es la herramienta estándar para computación paralela en R. Proporciona funciones para:

- `mclapply()`: Versión paralela de `lapply()` (solo Unix/Linux)
- `parLapply()`: Versión paralela multiplataforma
- `makeCluster()`: Crear clusters de trabajadores
- `clusterApply()`: Aplicar funciones en clusters

6.2 Funciones Principales

```
library(parallel)

# Detectar número de núcleos
num_cores <- detectCores()

# Ejemplo con mclapply (Unix/Linux/Mac)
result <- mclapply(data, function(x) {
  # Tu función aquí
}, mc.cores = num_cores)

# Ejemplo con clusters (Multiplataforma)
cl <- makeCluster(num_cores)
result <- parLapply(cl, data, function(x) {
  # Tu función aquí
})
stopCluster(cl)
```

i Trabajo en Progreso

Esta traducción está en desarrollo. El contenido completo incluirá ejemplos detallados, comparaciones de rendimiento y mejores prácticas para usar el paquete parallel.

Part III

Trabajando con un Cluster

7 Fundamentos de SLURM

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

8 ¿Qué es Slurm?

Note

La mayor parte de esta sección fue extraída de la viñeta del paquete R `slurmR` “[Working with Slurm.](#)”

Hoy en día, los clústeres de computación de alto rendimiento (HPC) son herramientas comúnmente disponibles tanto en configuraciones en la nube como fuera de ella. [Slurm Work Manager](#) (anteriormente *Simple Linux Utility for Resource Manager*) es un programa escrito en C que se usa para gestionar eficientemente recursos en clústeres HPC. El paquete R `slurmR`—que estaremos usando en este libro—proporciona herramientas para usar R en configuraciones HPC que funcionan con Slurm. Proporciona envoltorios y funciones que permiten al usuario integrar sin problemas su pipeline de análisis con clústeres HPC, enfatizando en proporcionar al usuario una familia de funciones similares a las que proporciona el paquete R `parallel`.

8.1 Definiciones

Primero, algunos puntos de discusión importantes dentro del contexto de Slurm+R que los usuarios, en general, encontrarán útiles. La mayoría de los puntos tienen que ver con opciones disponibles para Slurm, y en particular, con el comando `sbatch` que se usa para enviar trabajos en lote a Slurm. Los usuarios que han usado Slurm en el pasado pueden desear omitir esto y continuar leyendo la siguiente sección.

- **Nodo** Una sola computadora en el HPC: Muchas veces los trabajos se enviarán a un solo nodo. La forma más simple de usar R+Slurm es enviar un solo trabajo y solicitar múltiples CPUs para usar, por ejemplo, `parallel::parLapply` o `parallel::mclapply`. Usualmente, los usuarios no necesitan solicitar un número específico de nodos para ser usados ya que Slurm asignará los recursos según sea necesario.

Un error común de los usuarios de R es especificar el número de nodos y esperar que su script sea paralelizado. Esto no sucederá a menos que el usuario escriba explícitamente un script de computación paralela.

La bandera relevante para `sbatch` es `--nodes`.

- **Partición** Un grupo de nodos en HPC. Generalmente los nodos grandes pueden tener múltiples particiones, lo que significa que los nodos pueden ser agrupados de varias maneras. Por ejemplo, los nodos pertenecientes a un solo grupo de usuarios pueden estar en una sola partición, y los nodos dedicados a trabajar con datos grandes pueden estar en otra partición. Usualmente, las particiones están asociadas con privilegios de cuenta, así que los usuarios pueden necesitar especificar qué cuenta están usando cuando le dicen a Slurm qué partición planean usar.

La bandera relevante para `sbatch` es `--partition`.

- **Cuenta** Las cuentas pueden estar asociadas con particiones. Las cuentas pueden tener privilegios para usar una partición o conjunto de nodos. A menudo, los usuarios necesitan especificar la cuenta cuando envían trabajos a una partición particular.

La bandera relevante para `sbatch` es `--account`.

- **Tarea** Un paso dentro de un trabajo. Un trabajo particular puede tener múltiples tareas. Las tareas pueden abarcar múltiples nodos, así que si el usuario quiere enviar un trabajo multinúcleo, esta opción puede no ser la correcta.

La bandera relevante para `sbatch` es `--ntasks`

- **CPU** generalmente esto se refiere a núcleo o hilo (que puede ser diferente en sistemas que soportan núcleos multihilo). Los usuarios pueden querer especificar cuántos CPUs quieren usar para una tarea. Y esta es la opción relevante cuando se usan cosas como OpenMP o funciones que permiten crear objetos de clúster en R (p. ej. `makePSOCKcluster`, `makeForkCluster`).

La opción relevante en `sbatch` es `--cpus-per-task`. Más información sobre CPUs en Slurm se puede encontrar [aquí](#). Información sobre cómo Slurm cuenta CPUs/núcleos/hilos se puede encontrar [aquí](#).

- **Array de Trabajos** Slurm soporta arrays de trabajos. Un array de trabajos es en términos simples un trabajo que es repetido múltiples veces por Slurm, esto es, replica un solo trabajo según lo solicitado por el usuario. En el caso de R, cuando se usa esta opción, un solo script R se extiende en múltiples trabajos, así que el usuario puede tomar ventaja de esto y paralelizar trabajos a través de múltiples nodos. Además del hecho de que los trabajos dentro de un Array de Trabajos pueden extenderse a través de múltiples nodos, cada trabajo en ese array tiene un ID único que está disponible para el usuario vía variables de entorno, en particular `SLURM_ARRAY_TASK_ID`.

Dentro de R, y por tanto el Rscript enviado a Slurm, los usuarios pueden acceder a esta variable de entorno con `Sys.getenv("SLURM_ARRAY_TASK_ID")`. Algunas de las funcionalidades de `slurmR` dependen de Arrays de Trabajos.

Más información sobre Arrays de Trabajos se puede encontrar [aquí](#). La opción relevante para esto en `sbatch` es `--array`.

Más información sobre Slurm se puede encontrar en su sitio web oficial [aquí](#). Un tutorial sobre cómo usar Slurm con R se puede encontrar [aquí](#).

9 Una introducción breve a Slurm

Para una introducción rápida y sucia a Slurm (Yoo, Jette, and Grondona 2003), comenzaremos con un simple “Hola mundo” usando Slurm + R. Para esto, necesitamos pasar por los siguientes pasos:

1. Copiar un script de Slurm a HPC,
2. Iniciar sesión en HPC, y
3. Enviar el trabajo usando `sbatch`.

9.1 Paso 1: Copiar el script de Slurm a HPC

Necesitamos copiar el siguiente script de Slurm a HPC ([00-hello-world.slurm](#)):

```
#!/bin/sh
#SBATCH --output=00-hello-world.out
module load R/4.2.2
Rscript -e "paste('Hello from node', Sys.getenv('SLURMD_NODENAME'))"
```

Que tiene cuatro líneas:

1. `#!/bin/sh`: El **shebang** ([¿she qué?](#))
2. `#SBATCH --output=00-hello-world.out`: Una opción para ser pasada a `sbatch`, en este caso, el nombre del archivo de salida al cual irán **stdout y stderr**.
3. `module load R/4.2.2`: Usa **Lmod** para cargar el módulo R.
4. `Rscript ...`: Una llamada a R para evaluar la expresión `paste(...)`. Esto obtendrá la variable de entorno `SLURMD_NODENAME` (que `sbatch` crea) y la imprimirá en un mensaje.

Para hacer esto, usaremos **Protocolo de copia segura (scp)**, que nos permite copiar datos hacia y desde computadoras. En este caso, deberíamos hacer algo como lo siguiente

```
scp 00-hello-world.slurm [userid]@notchpeak.chpc.utah.edu:/ruta/a/un/lugar/que/puedas/ac
```

En palabras, “Usando el nombre de usuario [userid], conectar a `notchpeak.chpc.utah.edu`, tomar el archivo `00-hello-world.slurm` y copiarlo a /ruta/a/un/lugar/que/puedas/acceder. Con el archivo ahora disponible en el clúster, podemos enviar este trabajo usando Slurm.

9.2 Paso 2: Iniciar sesión en HPC

1. Iniciar sesión usando ssh. En el caso de usuarios de Windows, descargar el cliente [Putty](#).
2. Para iniciar sesión, necesitarás usar tu ID de organización. Usualmente, si tu email es algo como `miusuarioemail@escuela.edu`, tu ID es `miusuarioemail`. Entonces:

```
ssh miusuarioemail@notchpeak.chpc.utah.edu
```

9.3 Paso 3: Enviando el trabajo

En general, hay dos formas de usar los nodos de cómputo: interactivamente (`salloc`) y en modo por lotes (`sbatch`). En este caso, ya que tenemos un script de Slurm, usaremos este último.

Para enviar el trabajo, podemos escribir lo siguiente:

```
sbatch 00-hello-world.slurm
```

¡Y eso es todo! Dicho eso, a menudo se requiere especificar la cuenta y partición que el usuario estará enviando el trabajo. Por ejemplo, si tienes la cuenta `mi-cuenta` y partición `mi-partición` asociadas con tu usuario, puedes incorporar esa información como sigue:

```
sbatch 00-hello-world.slurm --account=mi-cuenta --partition=mi-partición
```

En el caso de sesiones interactivas, puedes iniciar una usando el comando `salloc`. Por ejemplo, si quisieras ejecutar R con 8 núcleos, usando 16 Gigs de memoria en total, necesitarías hacer lo siguiente:

```
salloc -n1 --cpus-per-task=8 --mem-per-cpu=2G --time=01:00:00
```

Una vez que tu solicitud es enviada, obtendrás acceso a un nodo de cómputo. Dentro de él, puedes cargar los módulos requeridos e iniciar R:

```
module load R/4.2.2
R
```

Las sesiones interactivas no se recomiendan para trabajos largos. En su lugar, usa este recurso si necesitas inspeccionar algún conjunto de datos grande, depurar tu código, etc.

10 SLURM con Simulación de

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

11 Simulando π

El siguiente es un ejemplo que muchas personas (incluyéndome) han usado para ilustrar computación paralela con R. El ejemplo es directo: queremos aproximar π haciendo algunas simulaciones de Monte Carlo.

Sabemos que el área de un círculo es $A = \pi r^2$, que es equivalente a $\pi = A/r^2$, así que si podemos aproximar el Área de un círculo, entonces podemos aproximar π . ¿Cómo hacemos esto?

Usando experimentos de Monte Carlo, podemos aproximar la probabilidad de que un punto aleatorio x caiga dentro del círculo unitario usando la siguiente fórmula:

$$\hat{p} = \frac{1}{n} \sum_i \mathbf{1}(x \in \text{Círculo})$$

Esta aproximación, $\hat{p}$, multiplicada por el área del cuadrado que contiene al círculo, que tiene un área igual a $(2 \times r)^2$, así, finalmente podemos escribir

$$\hat{\pi} = \hat{p} \times (2 \times r)^2 / r^2 = 4\hat{p}$$




Figure 11.1: 10,000 puntos aleatorios dibujados dentro del círculo unitario.

11.1 Enviando trabajos a Slurm

Trabajaremos principalmente enviando trabajos usando la función `sbatch`. Esta función toma como su argumento principal un archivo bash con el programa a ejecutar. En el caso de R, un archivo bash regular se ve algo así:

```
#!/bin/sh
#SBATCH --job-name=sapply
#SBATCH --time=00:10:00

module load R/4.2.2
Rscript --vanilla 01-sapply.R
```

Este archivo tiene tres componentes:

- **Las banderas de Slurm #SBATCH:** Estas entradas parecidas a comentarios pasan opciones de Slurm al trabajo. En este ejemplo, solo especificamos las opciones `job-name` y `time`. Otras opciones comunes incluirían `account` y `partition`.
- **Cargando R `module load R/4.2.2`:** Dependiendo de la configuración de tu sistema, puedes o no necesitar cargar módulos o ejecutar scripts bash antes de poder ejecutar R. En este ejemplo, estamos cargando R versión 4.2.2 usando `LMod` (ver sección anterior).

- **Ejecutando el script R:** Después de especificar opciones de Slurm y cargar lo que necesita ser cargado antes de ejecutar R, estamos usando `RScript` para ejecutar el programa que escribimos.

El envío se hace entonces como sigue:

```
sbatch 01-sapply.slurm
```

Los siguientes ejemplos tienen dos archivos, un script bash y un script R, para ser llamado por Slurm.

11.1.1 Caso 1: Trabajo único, trabajo de un solo núcleo

La forma más básica es enviar un trabajo usando el comando `sbatch`. En este caso, debes tener dos archivos: (1) Un script R y (2) un script bash. p. ej.

Los contenidos del script R ([01-sapply.R](#)) son:

```
# Model parameters
nsims <- 1e3
n      <- 1e4

# Function to simulate pi
simpi <- function(i) {

  p <- matrix(runif(n*2, -1, 1), ncol = 2)
  mean(sqrt(rowSums(p^2)) <= 1) * 4

}

# Approximation
set.seed(12322)
ans <- sapply(1:nsims, simpi)

message("Pi: ", mean(ans))

saveRDS(ans, "01-sapply.rds")
```

Los contenidos del archivo bash ([01-sapply.slurm](#)) son:

```
#!/bin/sh
#SBATCH --job-name=sapply
#SBATCH --time=00:10:00

module load R/4.2.2
Rscript --vanilla 01-sapply.R
```

11.1.2 Caso 2: Trabajo único, trabajo multinúcleo

Imagina que nos gustaría usar más de un procesador para este trabajo, usando la función `parallel::mclapply` del paquete `parallel`.¹ Entonces, además de adaptar el código, necesitamos decirle a Slurm que estamos usando más de un núcleo por tarea, como en el siguiente ejemplo:

Script R ([02-mclapply.R](#)):

```
# Model parameters
nsims  <- 1e3
n      <- 1e4
ncores <- 4L

# Function to simulate pi
simpi <- function(i) {

  p <- matrix(runif(n*2, -1, 1), ncol = 2)
  mean(sqrt(rowSums(p^2)) <= 1) * 4

}

# Approximation
set.seed(12322)
ans <- parallel::mclapply(1:nsims, simpi, mc.cores = ncores)
ans <- unlist(ans)

message("Pi: ", mean(ans))

saveRDS(ans, "02-mclpplpy.rds")
```

Archivo bash ([02-mclapply.slurm](#)):

¹Esta función es una especie de envoltorio de `makeForkcluster`. [Forking](#) proporciona una forma de duplicar un proceso en el SO sin replicar la memoria, lo cual es tanto más rápido como eficiente.

```
#!/bin/sh
#SBATCH --job-name=mclapply
#SBATCH --time=00:10:00
#SBATCH --cpus-per-task=4

module load R/4.2.2
Rscript --vanilla 02-mclapply.R
```

11.2 Trabajos con el paquete slurmR

El paquete R `slurmR` (Vega Yon and Marjoram 2019, 2022) es un envoltorio ligero de Slurm. Las funciones principales del paquete son la familia `*apply`—principalmente a través de arrays de trabajos Slurm—y `makeSlurmCluster()`—que es un envoltorio de `makePSOCKcluster`.

Esta sección ilustrará cómo enviar trabajos usando la función `makeSlurmCluster()` y `Slurm_sapply`. Además, el último ejemplo demuestra cómo podemos omitir escribir scripts Slurm completamente usando la función `sourceSlurm()` incluida en el paquete.

11.2.1 Caso 3: Trabajo único, trabajo multinodo

En este caso, no hay una forma simple de enviar un trabajo multinodal a Slurm; a menos que uses el paquete `slurmR`.² En este ejemplo, combinaremos `slurmR` con la función `parSapply` del paquete `parallel` para enviar un trabajo multinodal usando la función `makeSlurmCluster()`. Con ella, `slurmR` enviará un trabajo solicitando `njobs` tareas (procesadores) que podrían abarcar múltiples nodos,³ y crear un clúster Socket de él (como usar `makePSOCKcluster`.) Una cosa a tener en mente es que los clústeres Socket están limitados en el número de conexiones que una sola sesión R puede abarcar. Puedes leer más sobre eso [aquí](#) y [aquí](#).

Script R ([03-parsapply-slurmR.R](#)):

```
# Model parameters
nsims  <- 1e3
n      <- 1e4
ncores <- 4L

# Function to simulate pi
simpi <- function(i) {
```

²Ver instrucciones de instalación [aquí](#)

³Aunque posible, la mayoría de trabajos multinodo serán asignados si no hay suficientes hilos dentro de un solo nodo. Recuerda que Slurm no ejecuta los trabajos sino que reserva recursos computacionales para que los ejecutes.

```

p <- matrix(runif(n*2, -1, 1), ncol = 2)
mean(sqrt(rowSums(p^2)) <= 1) * 4
}

# Setting up slurmR
library(slurmR) # This also loads the parallel package

# Making the cluster, and exporting the variables
cl <- makeSlurmCluster(ncores)

# Approximation
clusterExport(cl, c("n", "simpi"))
ans <- parSapply(cl, 1:nsims, simpi)

# Closing connection
stopCluster(cl)

message("Pi: ", mean(ans))

saveRDS(ans, "03-parsapply-slurmr.rds")

```

Archivo bash (03-parsapply-slurmr.slurm):

```

#!/bin/sh
#SBATCH --job-name=parsapply
#SBATCH --time=00:10:00

module load R/4.2.2
Rscript --vanilla 03-parsapply-slurmr.R

```

11.2.2 Caso 4: Múltiples trabajos, un solo/múltiples núcleos

Otra forma de enviar trabajos es usando **arrays de trabajos**. Un array de trabajos es un trabajo repetido `njobs` veces con la misma configuración. La principal diferencia entre réplicas es lo que haces con la variable de entorno `SLURM_ARRAY_TASK_ID`. Esta variable se define dentro de cada réplica y puede usarse para hacer el “subtrabajo” dependiendo de eso.

Aquí hay un ejemplo rápido usando R

```
ID <- Sys.getenv("SLURM_ARRAY_TASK_ID")
if (ID == 1) {
  ...[haz esto]...
} else if (ID == 2) {
  ...[haz eso]...
}
```

El paquete R `slurmR` hace fácil enviar arrays de trabajos. Nuevamente, con la simulación de pi, podemos hacerlo de la siguiente manera:

Script R ([04-slurm_sapply.R](#)):

```
# Model parameters
nsims <- 1e3
n      <- 1e4
# ncores <- 4L
njobs  <- 4L

# Function to simulate pi
simpi <- function(i, n.) {

  p <- matrix(runif(n.*2, -1, 1), ncol = 2)
  mean(sqrt(rowSums(p^2)) <= 1) * 4

}

# Setting up slurmR
library(slurmR) # This also loads the parallel package

# Approximation
ans <- Slurm_sapply(
  1:nsims, simpi,
  n.      = n,
  njobs   = njobs,
  plan    = "collect",
  tmp_path = "/scratch/vegayon" # This is where all temp files will be exported
)

message("Pi: ", mean(ans))

saveRDS(ans, "04-slurm_sapply.rds")
```

Archivo bash ([04-slurm_sapply.slurm](#)):

```
#!/bin/sh
#SBATCH --job-name=slurm_sapply
#SBATCH --time=00:10:00

module load R/4.2.2
Rscript --vanilla 04-slurm_sapply.R
```

Uno de los principales beneficios de usar este enfoque en lugar de la función `makeSlurmCluster` (y así, trabajar con un clúster SOCK) son:

- El número de trabajos no está limitado aquí (solo por el administrador, pero no por R).
- Si un trabajo falla, entonces podemos volver a ejecutarlo usando `sbatch` una vez más (ver ejemplo [aquí](#)).
- Puedes verificar los logs individuales de cada proceso usando la función `Slurm_lob()`.
- Puedes enviar el trabajo y salir de la sesión R sin esperar a que finalice. Siempre puedes leer de vuelta el trabajo usando la función `read_slurm_job([ruta-al-temp])`

11.2.3 Caso 5: Omitiendo el archivo `.slurm`

El paquete `slurmR` tiene una función llamada `sourceSlurm` que puede usarse para evitar crear el archivo `.slurm`. El usuario puede agregar las opciones `SBATCH` al principio del script R (incluyendo la línea `#!/bin/sh`) y enviar el trabajo desde R como sigue:

Script R ([05-sapply.R](#)):

```
#!/bin/sh
#SBATCH --job-name=sapply-sourceSlurm
#SBATCH --time=00:10:00

# Model parameters
nsims <- 1e3
n      <- 1e4

# Function to simulate pi
simpi <- function(i) {

  p <- matrix(runif(n*2, -1, 1), ncol = 2)
  mean(sqrt(rowSums(p^2)) <= 1) * 4

}
```

```
# Approximation
set.seed(12322)
ans <- sapply(1:nsims, simpi)

message("Pi: ", mean(ans))

saveRDS(ans, "05-sapply.rds")
```

Desde la consola R (está bien si estás en el nodo cabeza)

```
slurmR::sourceSlurm("05-sapply.R")
```

¡Y voilà! Se generará un archivo bash temporal para enviar el script R a la cola. El siguiente video muestra una posible salida en el CHPC de la Universidad de Utah con slurmR versión 0.5-3:

<https://youtu.be/OasEla5EszI>

Part IV

Usando C++

12 Rcpp Parte 1

[El contenido completo de este capítulo será traducido al español. Por ahora, esta es una versión preliminar.]

12.1 Introducción a Rcpp

Rcpp es un paquete de R que facilita la integración de código C++ con R. Permite:

- Escribir funciones C++ que pueden ser llamadas desde R
- Acceso eficiente a objetos de R desde C++
- Mejoras significativas de rendimiento para cálculos intensivos

12.2 ¿Por qué usar C++ con R?

1. **Velocidad:** C++ es considerablemente más rápido para bucles y cálculos intensivos
2. **Control de memoria:** Mejor gestión de memoria para datos grandes
3. **Librerías existentes:** Acceso a librerías C++ optimizadas
4. **Algoritmos personalizados:** Implementación de algoritmos especializados

12.3 Primer Ejemplo

```
#include <Rcpp.h>
using namespace Rcpp;

// [[Rcpp::export]]
double suma_cpp(NumericVector x) {
    double resultado = 0;
    for(int i = 0; i < x.size(); i++) {
        resultado += x[i];
    }
    return resultado;
}
```

i Trabajo en Progreso

Esta traducción está en desarrollo. El contenido completo incluirá ejemplos prácticos, tipos de datos, y mejores prácticas para programación con Rcpp.

13 Depuración de R con código C++/C

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

14 Depuración de R con código C++/C

Aunque depurar código R es fácil, lo mismo no aplica para código compilado en R¹. Este capítulo muestra algunas formas de depurar tu código R + C++. Necesitarás el [GNU Debugger \(GDB\)](#) y [Valgrind](#).

Antes de comenzar, recuerda que no vamos a lidiar con el buen enfoque de toda la vida `Rprint("Tu código está funcionando hasta aquí")`. Imprimir mensajes mientras tu programa se ejecuta puede ser muy informativo, pero usar Valgrind y GDB es, en mi humilde opinión, más rápido ya que, la mayoría del tiempo, esos te gritarán, indicando la ubicación de tu problema.

Note

El manual [Writing R Extensions](#) (R Core Team 2023) tiene una cantidad considerable de información sobre depurar código compilado en R [aquí](#). [Dirk Eddelbuettel](#) (autor principal de Rcpp) tiene un [excelente post en Stackoverflow](#) y recomienda [un tutorial alojado en BioConductor](#) (Rue-Albrecht et al. n.d.).

14.1 Depuración con Valgrind

Como punto de partida, usaremos Valgrind. Valgrind proporciona un marco de trabajo maduro para depuración y perfilado de memoria. Debemos lanzar el programa a través de la línea de comandos para usar un depurador dentro de R. Para lanzar R con Valgrind, usamos lo siguiente:

```
$ R --debugger=valgrind
```

Lo cual resultará en algo como lo siguiente:

```
==31245== Memcheck, a memory error detector
==31245== Copyright (C) 2002-2017, and GNU GPL'd, by Julian Seward et al.
==31245== Using Valgrind-3.18.1 and LibVEX; rerun with -h for copyright info
==31245== Command: /usr/lib/R/bin/exec/R
```

¹Depurar **solo** código C++/C es fácil, sin embargo. Si ya trabajas con código compilado, debes estar consciente de [VS Code](#) y las muchas otras herramientas por ahí para depurar código C++/C.

```
==31245==
```

```
R version 4.2.3 (2023-03-15) -- "Shortstop Beagle"  
Copyright (C) 2023 The R Foundation for Statistical Computing  
Platform: x86_64-pc-linux-gnu (64-bit)
```

```
R is free software and comes with ABSOLUTELY NO WARRANTY.  
You are welcome to redistribute it under certain conditions.  
Type 'license()' or 'licence()' for distribution details.
```

```
  Natural language support but running in an English locale
```

```
R is a collaborative project with many contributors.  
Type 'contributors()' for more information and  
'citation()' on how to cite R or R packages in publications.
```

```
Type 'demo()' for some demos, 'help()' for on-line help, or  
'help.start()' for an HTML browser interface to help.  
Type 'q()' to quit R.
```

```
>
```

Una vez que R se ejecuta con Valgrind, el depurador capturará cualquier fuga de memoria generada por tu código C++/C. Lo siguiente es un programa defectuoso de Rcpp que crea un puntero usando `new` y “olvida” eliminarlo.

```
#include <Rcpp.h>  
  
using namespace Rcpp;  
  
// [[Rcpp::export]]  
NumericVector faulty_program(int n) {  
  
    // Aquí está la línea defectuosa  
    NumericVector * x_ptr = new NumericVector(n);  
  
    return *x_ptr;  
  
}  
  
/****R  
# Calling the faulty program  
faulty_program(10)  
*/
```

Podemos usar la bandera `-e` en el comando `R` para compilar el script `Rcpp` usando `sourceCpp`:

```
R --debugger=valgrind -e 'Rcpp::sourceCpp("rcpp-debugging-faulty.cpp")'
```

```
==297== Memcheck, a memory error detector
==297== Copyright (C) 2002-2022, and GNU GPL'd, by Julian Seward et al.
==297== Using Valgrind-3.22.0 and LibVEX; rerun with -h for copyright info
==297== Command: /usr/local/lib/R/bin/exec/R -e Rcpp::sourceCpp("rcpp-debugging-faulty.c
==297==
```

```
R version 4.5.1 (2025-06-13) -- "Great Square Root"
Copyright (C) 2025 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu
```

```
R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.
```

```
Natural language support but running in an English locale
```

```
R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.
```

```
Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.
```

```
> Rcpp::sourceCpp("rcpp-debugging-faulty.cpp")
```

```
> faulty_program(10)
[1] 0 0 0 0 0 0 0 0 0 0
>
```

```
==297==
==297== HEAP SUMMARY:
==297==    in use at exit: 60,654,766 bytes in 11,486 blocks
==297== total heap usage: 31,685 allocs, 20,199 frees, 93,770,748 bytes allocated
==297==
==297== LEAK SUMMARY:
==297==    definitely lost: 32 bytes in 1 blocks
==297==    indirectly lost: 0 bytes in 0 blocks
==297==    possibly lost: 0 bytes in 0 blocks
==297==    still reachable: 60,654,734 bytes in 11,485 blocks
```

```

==297==                                of which reachable via heuristic:
==297==                                newarray                : 4,264 bytes in 1 blocks
==297==                                suppressed: 0 bytes in 0 blocks
==297== Rerun with --leak-check=full to see details of leaked memory
==297==
==297== For lists of detected and suppressed errors, rerun with: -s
==297== ERROR SUMMARY: 0 errors from 0 contexts (suppressed: 0 from 0)

```

Al final de la salida, en la sección LEAK SUMMARY, vemos `definitely lost: 24 bytes in 1 block`, *es decir*, una fuga de memoria. Si cambiamos el programa eliminando el puntero antes de retornar, la fuga se resolverá:

Nuevo programa:

```

NumericVector res = *x_ptr;
delete x_ptr;

return res;

```

Programa anterior

```

return *x_ptr;

```

Re-ejecutando R con Valgrind retorna lo siguiente (solo las últimas pocas líneas):

```

R --debugger=valgrind -e 'Rcpp::sourceCpp("rcpp-debugging-faulty-fixed.cpp")'

```

```

==354== HEAP SUMMARY:
==354==    in use at exit: 60,655,412 bytes in 11,485 blocks
==354== total heap usage: 31,722 allocs, 20,237 frees, 93,791,193 bytes allocated
==354==
==354== LEAK SUMMARY:
==354==    definitely lost: 0 bytes in 0 blocks
==354==    indirectly lost: 0 bytes in 0 blocks
==354==    possibly lost: 0 bytes in 0 blocks
==354==    still reachable: 60,655,412 bytes in 11,485 blocks
==354==                of which reachable via heuristic:
==354==                newarray                : 4,264 bytes in 1 blocks
==354==                suppressed: 0 bytes in 0 blocks
==354== Rerun with --leak-check=full to see details of leaked memory
==354==
==354== For lists of detected and suppressed errors, rerun with: -s
==354== ERROR SUMMARY: 0 errors from 0 contexts (suppressed: 0 from 0)

```


No más fugas de memoria.

14.2 Usando GDB

A veces, necesitamos ir más allá e inspeccionar qué está pasando **dentro** del programa. GDB es excelente para eso. Con GDB, podemos establecer puntos de interrupción que nos permiten revisar el programa mientras se ejecuta.

El siguiente código Rcpp genera un error de tipo `memory not mapped`:

```
#include <Rcpp.h>

using namespace Rcpp;

// [[Rcpp::export]]
NumericVector faulty_program(int n) {

    // Aquí está la línea defectuosa
    NumericVector * x_ptr;

    return *x_ptr;

}

/***R
# Calling the faulty program
faulty_program(10)
*/
```

En él, tratamos de acceder a una ubicación en la memoria que no ha sido asignada aún, es decir, un `NumericVector` declarado como un puntero pero nunca asignado. Usar `R --debugger=valgrind` genera el siguiente código:

```
==411== Memcheck, a memory error detector
==411== Copyright (C) 2002-2022, and GNU GPL'd, by Julian Seward et al.
==411== Using Valgrind-3.22.0 and LibVEX; rerun with -h for copyright info
==411== Command: /usr/local/lib/R/bin/exec/R -e Rcpp::sourceCpp("rcpp-debugging-not-mapped.cpp")
==411==

R version 4.5.1 (2025-06-13) -- "Great Square Root"
Copyright (C) 2025 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu
```

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.

Natural language support but running in an English locale

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.

```
> Rcpp::sourceCpp("rcpp-debugging-not-mapped.cpp")
```

```
> faulty_program(10)
```

```
==411== Invalid read of size 8
```

```
==411==    at 0x2EF4D5D6: get__ (PreserveStorage.h:52)
```

```
==411==    by 0x2EF4D5D6: copy__<Rcpp::Vector<14, Rcpp::PreserveStorage> > (PreserveStorage.h:100)
```

```
==411==    by 0x2EF4D5D6: Vector (Vector.h:64)
```

```
==411==    by 0x2EF4D5D6: faulty_program(int) (rcpp-debugging-not-mapped.cpp:11)
```

```
==411==    by 0x2EF4D758: sourceCpp_1_faulty_program (rcpp-debugging-not-mapped.cpp:33)
```

```
==411==    by 0x495D56D: R_doDotCall (dotcode.c:754)
```

```
==411==    by 0x495DAE6: do_dotcall (dotcode.c:1437)
```

```
==411==    by 0x49AC44C: Rf_eval (eval.c:1260)
```

```
==411==    by 0x49AE06D: R_execClosure (eval.c:2393)
```

```
==411==    by 0x49AEDC6: applyClosure_core (eval.c:2306)
```

```
==411==    by 0x49ABF65: Rf_applyClosure (eval.c:2328)
```

```
==411==    by 0x49ABF65: Rf_eval (eval.c:1280)
```

```
==411==    by 0x49B2AD3: do_eval (eval.c:3959)
```

```
==411==    by 0x499EDD4: bcEval_loop (eval.c:8118)
```

```
==411==    by 0x49ABA59: bcEval (eval.c:7501)
```

```
==411==    by 0x49ABA59: bcEval (eval.c:7486)
```

```
==411==    by 0x49ABE2A: Rf_eval (eval.c:1167)
```

```
==411== Address 0x0 is not stack'd, malloc'd or (recently) free'd
```

```
==411==
```

```
*** caught segfault ***
```

```
address (nil), cause 'memory not mapped'
```

```
Traceback:
```

```
1: .Call(<pointer: 0x2ef4d6e0>, n)
```

```
2: faulty_program(10)
```

```

3: eval(ei, envir)
4: eval(ei, envir)
5: withVisible(eval(ei, envir))
6: source(file = srcConn, local = env, echo = echo)
7: Rcpp::sourceCpp("rcpp-debugging-not-mapped.cpp")
An irrecoverable exception occurred. R is aborting now ...
==411==
==411== Process terminating with default action of signal 11 (SIGSEGV): dumping core
==411==   at 0x4D6AB2C: __pthread_kill_implementation (pthread_kill.c:44)
==411==   by 0x4D6AB2C: __pthread_kill_internal (pthread_kill.c:78)
==411==   by 0x4D6AB2C: pthread_kill@@GLIBC_2.34 (pthread_kill.c:89)
==411==   by 0x4D1127D: raise (raise.c:26)
==411==   by 0x4D1132F: ??? (in /usr/lib/x86_64-linux-gnu/libc.so.6)
==411==   by 0x2EF4D5D5: copy__<Rcpp::Vector<14, Rcpp::PreserveStorage> > (PreserveStorage.cpp:11)
==411==   by 0x2EF4D5D5: Vector (Vector.h:64)
==411==   by 0x2EF4D5D5: faulty_program(int) (rcpp-debugging-not-mapped.cpp:11)
==411==
==411== HEAP SUMMARY:
==411==   in use at exit: 60,747,092 bytes in 11,700 blocks
==411== total heap usage: 31,654 allocs, 19,954 frees, 93,747,852 bytes allocated
==411==
==411== LEAK SUMMARY:
==411==   definitely lost: 0 bytes in 0 blocks
==411==   indirectly lost: 0 bytes in 0 blocks
==411==   possibly lost: 5,987 bytes in 19 blocks
==411==   still reachable: 60,741,105 bytes in 11,681 blocks
==411==                 of which reachable via heuristic:
==411==                   newarray           : 4,264 bytes in 1 blocks
==411==   suppressed: 0 bytes in 0 blocks
==411== Rerun with --leak-check=full to see details of leaked memory
==411==
==411== For lists of detected and suppressed errors, rerun with: -s
==411== ERROR SUMMARY: 1 errors from 1 contexts (suppressed: 0 from 0)
Segmentation fault (core dumped)

```

Para inspeccionar un error con GDB, tenemos que seguir estos pasos:

1. Ejecutar R con gdb como depurador: `R --debugger=gdb`. R no iniciará inmediatamente, así que tenemos tiempo para agregar puntos de interrupción.

```
george@george-XPS-13-9310: ~/Documents/content/h...
george@george-XPS-13-9310:~/Documents/content/hpcwithr$ R -d gdb
GNU gdb (Ubuntu 12.1-0ubuntu1~22.04) 12.1
Copyright (C) 2022 Free Software Foundation, Inc.
License GPLv3+: GNU GPL version 3 or later <http://gnu.org/licenses/gpl.html>
>
This is free software: you are free to change and redistribute it.
There is NO WARRANTY, to the extent permitted by law.
Type "show copying" and "show warranty" for details.
This GDB was configured as "x86_64-linux-gnu".
Type "show configuration" for configuration details.
For bug reporting instructions, please see:
<https://www.gnu.org/software/gdb/bugs/>.
Find the GDB manual and other documentation resources online at:
<http://www.gnu.org/software/gdb/documentation/>.

For help, type "help".
Type "apropos word" to search for commands related to "word"...
Reading symbols from /usr/lib/R/bin/exec/R...
(No debugging symbols found in /usr/lib/R/bin/exec/R)
(gdb) 
```

2. Podemos establecer un punto de interrupción en la función dada con `break faulty_program`. GDB lo capturará sobre la marcha, así que elige `yes`. Es muy probable que te advierta que no hay símbolo para esa función.

```
george@george-XPS-13-9310: ~/Documents/content/h...
Copyright (C) 2022 Free Software Foundation, Inc.
License GPLv3+: GNU GPL version 3 or later <http://gnu.org/licenses/gpl.html>
>
This is free software: you are free to change and redistribute it.
There is NO WARRANTY, to the extent permitted by law.
Type "show copying" and "show warranty" for details.
This GDB was configured as "x86_64-linux-gnu".
Type "show configuration" for configuration details.
For bug reporting instructions, please see:
<https://www.gnu.org/software/gdb/bugs/>.
Find the GDB manual and other documentation resources online at:
<http://www.gnu.org/software/gdb/documentation/>.

For help, type "help".
Type "apropos word" to search for commands related to "word"...
Reading symbols from /usr/lib/R/bin/exec/R...
(No debugging symbols found in /usr/lib/R/bin/exec/R)
(gdb) break faulty_program
Function "faulty_program" not defined.
Make breakpoint pending on future shared library load? (y or [n]) y
Breakpoint 1 (faulty_program) pending.
(gdb) 
```

3. Ejecutar R usando el comando `run` en gdb:

```
george@george-XPS-13-9310: ~/Documents/content/h...
(gdb) run
Starting program: /usr/lib/R/bin/exec/R
[Thread debugging using libthread_db enabled]
Using host libthread_db library "/usr/lib/x86_64-linux-gnu/libthread_db.so.1".

R version 4.2.3 (2023-03-15) -- "Shortstop Beagle"
Copyright (C) 2023 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.


  Natural language support but running in an English locale

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.

[Detaching after vfork from child process 57230]
[Detaching after vfork from child process 57232]
> 
```

4. Obtener el programa usando `Rcpp::sourceCpp`, y esperar a que `gdb` pause el programa una vez que alcance el punto de interrupción.

A terminal window with a dark background and light text. The window title bar shows the user 'george' on a machine named 'george-XPS-13-9310' in the directory '~/Documents/content/h...'. The terminal content shows the execution of 'gdb run', which starts the R program. It displays the R version (4.2.3), copyright (2023), and platform (x86_64-pc-linux-gnu). It also shows the R license notice and some helpful messages. At the bottom, it shows the debugger detaching from child processes and then executing a command to source a C++ file.

```
george@george-XPS-13-9310: ~/Documents/content/h...
(gdb) run
Starting program: /usr/lib/R/bin/exec/R
[Thread debugging using libthread_db enabled]
Using host libthread_db library "/usr/lib/x86_64-linux-gnu/libthread_db.so.1".

R version 4.2.3 (2023-03-15) -- "Shortstop Beagle"
Copyright (C) 2023 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.

  Natural language support but running in an English locale

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.

[Detaching after vfork from child process 57230]
[Detaching after vfork from child process 57232]
> Rcpp::sourceCpp("rcpp-debugging-not-mapped.cpp")
```

5. Una vez que el programa se ha pausado, podemos inspeccionar el contexto.

```
george@george-XPS-13-9310: ~/Documents/content/h...
Platform: x86_64-pc-linux-gnu (64-bit)

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.

Natural language support but running in an English locale

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.

[Detaching after vfork from child process 57230]
[Detaching after vfork from child process 57232]
> Rcpp::sourceCpp("rcpp-debugging-not-mapped.cpp")
[Detaching after vfork from child process 57377]

> # Calling the faulty program
> faulty_program(10)

Breakpoint 1, faulty_program (n=10) at rcpp-debugging-not-mapped.cpp:6
6 NumericVector faulty_program(int n) {
(gdb) □
```

Debido al número de opciones que tiene, usar GBD puede ser abrumador. Aquí está la lista de comandos que uso más:

help	# Obtener ayuda
info locals	# Listar las variables locales (alcance)
info args	# Listar los argumentos pasados a la función
list	# Ver las últimas pocas líneas del código fuente
continue	# Continuar ejecutando el programa
next	# Ejecutar el siguiente paso
bt	# Mostrar toda la pila de llamadas (backtrace)
up	# Subir un nivel en la pila de llamadas
down	# Bajar un nivel en la pila de llamadas
print	# Imprimir/mostrar una expresión

Y aquí hay un ejemplo usando `info locals`, `info args`, `list`, y `print`.

```
george@george-XPS-13-9310: ~/Documents/content/h...
[Detaching after vfork from child process 57232]
> Rcpp::sourceCpp("rcpp-debugging-not-mapped.cpp")
[Detaching after vfork from child process 57377]

> # Calling the faulty program
> faulty_program(10)

Breakpoint 1, faulty_program (n=10) at rcpp-debugging-not-mapped.cpp:6
6      NumericVector faulty_program(int n) {
(gdb) info locals
x_ptr = <optimized out>
(gdb) info args
n = 10
(gdb) list
1      #include <Rcpp.h>
2
3      using namespace Rcpp;
4
5      // [[Rcpp::export]]
6      NumericVector faulty_program(int n) {
7
8          // Here is the faulty line
9          NumericVector * x_ptr;
10
(gdb) print x_ptr
$1 = <optimized out>
(gdb) 
```

6. Finalmente, para salir del programa, escribe `exit` (similar a `q()` en R.)

15 Misceláneos

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

15.1 Recursos generales

El Centro de Computación de Investigación Avanzada (anteriormente HPCC) tiene toneladas de recursos en línea. Aquí hay un par de enlaces útiles:

- **Sitio web del Centro de Computación de Investigación Avanzada**
<https://carc.usc.edu>
- **Foro de usuarios (¡muy útil!)** <https://hpc-discourse.usc.edu/categories>
- **Monitorea tu cuenta** <https://hpcaccount.usc.edu/>
- **Plantillas de trabajos Slurm** <https://carc.usc.edu/user-information/user-guides/high-performance-computing/slurm-templates>
- **Usando R** <https://carc.usc.edu/user-information/user-guides/software-and-programming/r>

15.2 Punteros de datos

En mi humilde opinión, estas son las cosas más importantes que debes saber sobre la gestión de datos en el HPC de USC:

1. Haz tu transferencia de datos usando los nodos de transferencia (es más rápido).
2. Nunca uses tu directorio home como espacio de almacenamiento (usa en su lugar el espacio asignado de tu proyecto).
3. Usa el sistema de archivos scratch solo para datos temporales, es decir, nunca guardes archivos importantes en scratch.

4. Finalmente, además del **Protocolo de copia segura (scp)**, si eres como yo, trata de configurar un cliente GUI para mover tus datos (ver [esto](#)).

15.3 Las opciones de Slurm que se olvidaron de contarte...

Primero que nada, tienes que estar consciente de que lo único que hace Slurm es asignar recursos. Si tu aplicación usa computación paralela o no, esa es otra historia.

Aquí algunas opciones de las que necesitas estar consciente:

- **ntasks** (predeterminado 1) Esto le dice a Slurm cuántos procesos tendrás ejecutándose. Ten en cuenta que los procesos no necesitan estar en el mismo nodo (así que Slurm puede reservar espacio en múltiples nodos)
- **cpus-per-task** (predeterminado 1) Esto es cuántos CPUs cada tarea estará usando. Esto es lo que necesitas usar si estás usando OpenMP (o un paquete que use eso), o cualquier cosa que necesites mantener dentro del mismo nodo.
- **nodes** el número de nodos que quieres usar en tu trabajo. Esto es útil principalmente si te importa el número máximo (yo diría) de nodos que quieres que use tu trabajo. Entonces, por ejemplo, si quieres usar 8 núcleos para una sola tarea y forzarla a estar en el mismo nodo, agregarías la opción `--nodes=1/1`.
- **mem-per-cpu** (predeterminado 1GB) Esta es la cantidad MÍNIMA de memoria que quieres que Slurm asigne para la tarea. No es una barrera rígida, así que tu proceso puede ir por encima de eso.
- **time** (predeterminado 30min) Este también es un límite rígido, así que si tu trabajo toma más que el tiempo especificado, Slurm lo matará.
- **partition** (predeterminado “”) y **account** (predeterminado “”) estas dos opciones van juntas, esto le dice a Slurm qué recursos usar. Además de los recursos privados tenemos los siguientes:
 - **partición quick**: Cualquier trabajo que sea lo suficientemente pequeño (en términos de tiempo y memoria) irá por este camino. Este es usualmente el predeterminado si no especificas ninguna opción de memoria o tiempo.
 - **partición main**: Los trabajos que requieren más recursos irán en esta línea.
 - **partición scavenge**: Si necesitas un número masivo de recursos, y tienes un trabajo que no debería, en principio, tomar demasiado tiempo para finalizar (menos de un par de horas), y **estás de acuerdo con que alguien lo mate**, entonces esta cola es para ti. La partición Scavenge usa todos los recursos inactivos de las particiones privadas, así que si cualquiera de los propietarios solicita los recursos, Slurm cancelará tu trabajo, es decir, no tienes prioridad (ver [más](#)).

- **partición largemem**: Si necesitas mucha memoria, tenemos 4 nodos de 1TB para eso.

Más información sobre las particiones [aquí](#)

15.4 Buenas prácticas (recomendaciones)

Esto es lo que deberías usar como mínimo:

```
#SBATCH --output=simulation.out
#SBATCH --job-name=simulation
#SBATCH --time=04:00:00
#SBATCH --mail-user=[tu]@usc.edu
#SBATCH --mail-type=END,FAIL
```

- `output` es el nombre del archivo de registro al que Slurm escribirá.
- `job-name` es eso, el nombre del trabajo. Puedes usar esto para matar o al menos ser capaz de identificar qué es lo que estás ejecutando cuando usas `myqueue`
- `time` Trata siempre de establecer una estimación de tiempo (más un poco más) para tu trabajo.
- `mail-user`, `mail-type` para que Slurm te notifique cuando las cosas sucedan

También, en tu código R

- Cualquier I/O debería hacerse a Scratch (`/scratch/[tu id de red usc]`) o `Tmp` `Sys.getenv("TMPDIR")`.

15.5 Ejecutando R interactivamente

1. El HPC tiene varias piezas de software preinstaladas. R es una de esas.
2. Para acceder al software preinstalado, usamos el [sistema de módulos Lmod](#) (más información [aquí](#))
3. Tiene múltiples versiones de R instaladas. Usa tu favorita ejecutando

```
module load R/4.2.2/[número de versión]
```

Donde `[número de versión]` puede ser 3.5.6 y hasta 4.0.3 (la última actualización). El módulo `usc` automáticamente carga `gcc/8.3.0`, `openblas/0.3.8`, `openmpi/4.0.2`, y `pmix/3.1.3`.

4. Nunca es una buena idea usar tu directorio home para instalar paquetes R, por eso deberías tratar de usar un **enlace simbólico en su lugar**, así

```
cd ~  
mkdir -p /ruta/a/un/proyecto/con/mucho/espacio/R  
ln -s /ruta/a/un/proyecto/con/mucho/espacio/R R
```

De esta manera, cada vez que instales tus paquetes R, R tendrá como predeterminado esa ubicación

5. Puedes ejecutar sesiones interactivas en HPC, pero esto se recomienda hacerlo usando la función `salloc` en Slurm, en otras palabras, ¡NUNCA USES R (O CUALQUIER SOFTWARE) PARA HACER ANÁLISIS DE DATOS EN LOS NODOS CABEZA! Las opciones pasadas a `salloc` son las mismas opciones que pueden pasarse a `sbatch` (ver la siguiente sección). Por ejemplo, si necesito hacer algunos análisis en la partición `thomas` (que es privada y tengo acceso a ella), escribiría algo como

```
salloc --account=lc_pdt --partition=thomas --time=02:00:00 --mem-per-cpu=2G
```

Esto me pondría en un solo nodo asignando 2 gigs de memoria por un máximo de 2 horas.

15.6 NoNos cuando uses R

- Hacer cómputo en el nodo cabeza (compilar cosas está bien)
- Solicitar un número de nodos (a menos que sepas lo que estás haciendo)
- Usar tu directorio home para I/O
- Guardar información importante en Staging/Scratch

16 Referencias

Nota de Traducción

Esta versión del capítulo fue traducida de manera automática utilizando IA. El capítulo aún no ha sido revisado por un humano.

Referencias

- Dowle, Matt, and Arun Srinivasan. 2021. *Data.table: Extension of 'Data.frame'*. <https://CRAN.R-project.org/package=data.table>.
- LUMI consortium. 2023. "Documentation - Distribution and Binding." <https://docs.lumi-supercomputer.eu/runjobs/scheduled-jobs/distribution-binding/>.
- R Core Team. 2023. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. <https://www.R-project.org/>.
- Rue-Albrecht, Kevin, Daniela Cassol, Johannes Rainer, and Lori Shepherd. n.d. *Welcome / Bioconductor Packages: Development, Maintenance, and Peer Review*. Accessed May 2, 2023.
- Vega Yon, George, and Paul Marjoram. 2019. "slurmR: A Lightweight Wrapper for HPC with Slurm." *The Journal of Open Source Software* 4 (39). <https://doi.org/10.21105/joss.01493>.
- . 2022. *slurmR: A Lightweight Wrapper for 'Slurm'*. <https://github.com/USCbiostats/slurmR>.
- Yoo, Andy B., Morris A. Jette, and Mark Grondona. 2003. "SLURM: Simple Linux Utility for Resource Management." In *Job Scheduling Strategies for Parallel Processing*, edited by Dror Feitelson, Larry Rudolph, and Uwe Schwiegelshohn, 2862:44–60. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer Berlin Heidelberg. https://doi.org/10.1007/10968987_3.

16.1 Recursos Adicionales

16.1.1 Libros Recomendados

- **Advanced R** por Hadley Wickham
- **Efficient R Programming** por Colin Gillespie y Robin Lovelace
- **Parallel R** por Q. Ethan McCallum y Stephen Weston
- **Seamless R and C++ Integration with Rcpp** por Dirk Eddelbuettel

16.1.2 Sitios Web y Documentación

- [CRAN Task View: High-Performance Computing](#)
- [Rcpp Documentation](#)
- [SLURM Documentation](#)

- [R Parallel Computing](#)

16.1.3 Paquetes Relevantes

- `parallel`: Computación paralela básica
- `foreach`: Bucles paralelos
- `future`: Framework unificado para computación paralela
- `Rcpp`: Integración R/C++
- `data.table`: Procesamiento eficiente de datos
- `bench`: Benchmarking de código